

Addien Zakia Hidayat

5002231063

Perbedaan Machine Learning dan Deep Learning untuk Klasifikasi Citra dan Deteksi Objek

A. Pemahaman Dasar

a. Machine Learning

Machine Learning (ML) adalah paradigma pemrograman di mana sistem tidak diprogram secara eksplisit, melainkan dilatih menggunakan pola dari data. Sistem diberi banyak contoh input-output, lalu belajar aturan yang menghubungkan keduanya. ML tradisional dalam computer vision sangat bergantung pada feature engineering yang merupakan proses di mana seorang engineer secara manual merancang dan memilih fitur yang dianggap informatif dari gambar, seperti tepi, sudut, tekstur, atau warna.

b. Deep Learning

Deep Learning (DL) adalah subset dari ML yang berbasis Artificial Neural Networks (ANN) berlapis-lapis. Yang membedakan DL dari ML tradisional bukan hanya arsitekturnya, tapi filosofinya: DL menolak feature engineering manual. Sebaliknya, network belajar sendiri representasi fitur dari data mentah secara hierarkis dari fitur rendah di layer awal, hingga fitur tinggi di layer dalam.

B. Klasifikasi Citra

a. Pendekatan ML Tradisional

Pipeline klasifikasi citra dengan ML tradisional terdiri dari beberapa tahap yang terpisah dan berurutan.

1. Feature Extraction

- SIFT (Scale Invariant Feature Transform)
mendeteksi keypoint yang invariant terhadap perubahan skala, rotasi, dan sebagian perubahan iluminasi. Cocok untuk pencocokan gambar.
- SURF (Speeded Up Robust Features)
versi lebih cepat dari SIFT, menggunakan aproksimasi Hessian matrix.
- HOG (Histogram of Oriented Gradients)

menghitung distribusi arah gradien di region-region lokal. Sangat populer untuk deteksi manusia.

- **Color Histogram**

distribusi warna pixel dalam ruang warna tertentu (RGB, HSV).

Sederhana tapi sensitif terhadap perubahan iluminasi.

- **LBP (Local Binary Pattern)**

mendeskripsikan tekstur lokal berdasarkan hubungan intensitas pixel dengan tetangganya.

2. Feature Representation

Fitur-fitur yang diekstrak dikumpulkan dan direpresentasikan menjadi satu vektor deskriptor per gambar. Metode yang umum adalah **Bag of Visual Words (BoVW)**: semua fitur lokal dikuantisasi ke dalam vocabulary visual, lalu gambar direpresentasikan sebagai histogram frekuensi kemunculan setiap kata visual tersebut

3. Classification

- **SVM (Support Vector Machine)**: mencari hyperplane optimal yang memisahkan kelas. Sangat efektif untuk ruang fitur berdimensi tinggi.
 - **KNN (K-Nearest Neighbours)**: mengklasifikasikan sampel baru berdasarkan mayoritas label dari k tetangga terdekatnya di ruang fitur.
- Random Forest: ensemble dari banyak decision tree.

b. Pendekatan Deep Learning

CNN (Convolutional Neural Network) merevolusi klasifikasi citra dengan menghilangkan pemisahan antara feature extraction dan classification

Komponen utama CNN:

- **Convolutional Layer**

Layer ini mengaplikasikan filter (kernel) — sebuah matriks kecil berisi bobot yang dapat dipelajari — ke seluruh gambar dengan operasi konvolusi. Setiap filter mendeteksi satu jenis pola spesifik (tepi vertikal, tepi horizontal, sudut, dll). Dengan banyak filter di setiap layer, CNN membangun representasi fitur yang kaya. Operasinya adalah dot product antara kernel dan receptive field (area gambar yang sedang di-scan kernel).

- **Activation Function**

Output konvolusi dilewatkan ke fungsi aktivasi non-linear. ReLU (Rectified Linear Unit) paling populer karena tidak rentan terhadap vanishing gradient problem dan menghasilkan representasi yang sparse dan efisien. Sigmoid dan TanH juga digunakan tergantung kebutuhan.

- **Pooling Layer**

Setelah konvolusi, pooling layer mengurangi dimensi spasial untuk mengurangi komputasi dan memori, sekaligus memberikan invariansi terhadap translasi kecil. Max pooling mengambil nilai maksimum dalam setiap window.

- **Fully Connected Layer**

Setelah beberapa pasang conv-pool layer, feature map di-flatten menjadi vektor satu dimensi, lalu diproses oleh fully connected layer yang mirip neural network biasa.

- **Output Layer + Softmax**

Layer terakhir menghasilkan skor per kelas, lalu Softmax mengubahnya menjadi probabilitas (jumlahnya = 1).

Mengapa CNN lebih superior untuk klasifikasi:

Fitur yang dipelajari CNN bersifat hierarkis: layer pertama belajar tepi dan gradien sederhana, layer tengah belajar kombinasinya (sudut, kurva), layer dalam belajar representasi tingkat tinggi (bagian wajah, roda mobil, dll). Ini jauh lebih ekspresif daripada fitur hand-crafted. Selain itu, bobot kernel yang sama diaplikasikan ke seluruh gambar (parameter sharing), sehingga model bisa mengenali pola di mana pun posisinya dalam gambar.

Bukti empiris paling kuat adalah ImageNet Large Scale Visual Recognition Challenge (ILSVRC). Sejak AlexNet (Krizhevsky et al., 2012) memenangkan kompetisi dengan margin besar menggunakan CNN, semua state-of-the-art untuk klasifikasi citra didominasi DL.

Kapan ML tradisional masih relevan untuk klasifikasi:

Jika masalahnya sederhana dan bisa diselesaikan dengan satu atau dua aturan visual yang jelas, DL adalah overkill. Contoh klasik dari paper:

membedakan produk bercat merah vs biru di assembly line. Color thresholding sederhana cukup, lebih cepat, dan tidak perlu GPU mahal. DL baru worth it jika variasinya kompleks dan data tersedia banyak.

C. Deteksi Objek

a. Pendekatan ML Tradisional

Sliding Window + Feature Descriptor:

Pendekatan klasik adalah sliding window: sebuah window berukuran tetap digeser ke seluruh gambar di berbagai posisi dan skala. Di setiap posisi, fitur diekstrak (misalnya HOG) dan diklasifikasikan oleh SVM apakah region itu mengandung objek target atau tidak. Ini sangat tidak efisien karena jumlah kandidat region bisa mencapai puluhan ribu per gambar.

Viola-Jones (untuk deteksi wajah)

Salah satu metode paling sukses sebelum DL. Menggunakan Haar-like features dan cascade classifier untuk deteksi wajah real-time. Sangat efisien untuk satu kategori spesifik, tapi tidak generalizable ke kategori lain.

Deformable Part Models (DPM)

Merepresentasikan objek sebagai kombinasi dari beberapa part dengan model geometri yang fleksibel. Lebih robust terhadap deformasi, tapi parameternya kompleks untuk di-tune.

Kelemahan fundamental

Semua metode ini sangat domain-spesifik. Detector yang dirancang untuk deteksi wajah tidak bisa dipakai untuk deteksi mobil tanpa perombakan besar. Scaling ke banyak kelas sangat tidak praktis.

b. Pendekatan Deep Learning

DL merevolusi deteksi objek dengan beberapa arsitektur yang berbeda philosophy-nya

R-CNN (Region-based CNN)

Pendekatan dua tahap. Pertama, region proposal algorithm (Selective Search) mengusulkan ~2000 kandidat region per gambar. Kedua, setiap region

di-warp ke ukuran tetap lalu diproses CNN secara terpisah untuk ekstraksi fitur, kemudian SVM mengklasifikasikan tiap region dan regressor memperbaiki koordinat bounding box. Akurat tapi sangat lambat karena setiap region diproses terpisah.

Fast R-CNN dan Faster R-CNN

Solusi untuk masalah kecepatan R-CNN. Fast R-CNN memproses seluruh gambar sekali dengan CNN, lalu mengekstrak fitur untuk setiap region dari feature map yang sudah ada (bukan dari gambar asli). Faster R-CNN mengganti Selective Search dengan Region Proposal Network (RPN) yang juga berbasis CNN, sehingga seluruh pipeline menjadi satu kesatuan yang trainable end-to-end.

YOLO (You Only Look Once)

Filosofi berbeda: deteksi sebagai satu regression problem. Gambar dibagi jadi grid $S \times S$, setiap cell grid memprediksi bounding box dan probabilitas kelas secara langsung dalam satu forward pass. Sangat cepat (real-time), cocok untuk aplikasi video. Trade-off: akurasi sedikit lebih rendah untuk objek kecil.

SSD (Single Shot MultiBox Detector)

Menggabungkan keunggulan keduanya satu forward pass seperti YOLO, tapi menggunakan feature map dari berbagai skala untuk mendeteksi objek berbagai ukuran.